

공급사 상품명 기반 자동차 부품 카테고리 자동 분류 모델

데이터셋 선정 이유와 데이터 특성 기초 모델 적용 결과

상품명*

6PK2390

카테고리*

V벨트

추천 카테고리

모델 추천 상위 3개

V벨트

알터네이터

점화플러그

등록

상품 등록 화면 예시

문제 정의와 데이터셋

공급사 업계 표기 그대로 등록된 상품명

등록 상품명	실제 부품
쇼바고무(대) 카니발 후	쇼크업소버
앞등속(좌)	드라이브샤프트
연료모타(망) 세피아	연료펌프
겔벨트킷 GS300	V벨트

"쇼바", "등속" 등 업계 내부 용어 → 소비자 검색 · 판단 불가 · 남는 탐색 기준은 카테고리뿐

검색 · 추천 어디에도 노출되지 않는 상품

1,599건

카테고리 미지정 1,097건

"기타"로 저장 (기본값) 502건

선정 데이터셋 · 공급사 판매 상품

전체 상품

21,631

정답 카테고리 있음

19,955

공급사 · 카테고리

109 · 213

선정 이유

- 1 문제가 그대로 담긴 실제 상품명
- 2 정답 라벨 19,955건 → 추가 라벨링 없이 지도학습
- 3 미분류 1,599건에 바로 적용해 결과 확인

데이터 정제

특수기호 26종 전수 조사 → 1,524건 정제

기호만 제거	▲▲PT Cruiser2.0	→	PT Cruiser2.0
기호만 제거	㊟벤츠 뒤패드	→	벤츠 뒤패드
덩어리째 제거	{A} TENSIONER	→	TENSIONER
덩어리째 제거	(R1049=>B)마이티 드럼	→	마이티 드럼

기준: 부품 카테고리 판단에 기여하는가 · {A} · {B} 표기는 같은 카테고리로 확인 → 무관

상품명 자리의 메모 · 테스트 데이터 → 874건 제거

대체품 안내	IPEO-761로 대체
재고 · 출고 상태	출고정지 형상 다름
테스트 데이터 18건	테스트5 → 실린더블록
	에어필터 테스트 → 수입기타

상품명만으로 부품을 판별할 수 없어 학습 · 평가 모두에서 제외

정답 카테고리 있음

19,955

메모 · 테스트 데이터 제거

→ - 874

학습 대상

→ 19,081

데이터 특성

상품명 중복 비율

38.5%

19,081건 중 고유 상품명 11,736개

"브레이크 디스크 앞" 244회 · 학습 · 평가 동시 포함 시 누수

→ 같은 상품명은 1건만 남김

같은 이름, 다른 카테고리

142개

BRACKET → 5개 카테고리 · 67건(47%)은 동점
다수결 92.1% ± 0.4% vs 제외 92.9% ± 0.2%

→ 충돌 상품명 142개 제외

학습 대상 카테고리

208 → 74

상품명 20개 이상만 학습

평가 상품명 최소 4개 확보 · 커버리지 93.4%

→ 기준값 20은 7장에서 검증

단일 공급사 카테고리


4개

두 공급사 카테고리 9개 · "휠실린더 + 차종" 형식 반복
무작위 분할 시 형식 암기으로도 정답 가능

→ 공급사 단위 분할 병행

실험 설계

전처리



분할 방식

A. 무작위

상품명 8 : 2 · 학습 8,660 / 평가 2,166

기본 성능

B. 공급사 단위

공급사 통째로 8 : 2 · 학습 9,229 / 평가 1,597

처음 보는 공급사에도 통하는가?

입력과 모델

입력 · 글자 조각 단위

상품명을 1~4글자 조각으로 분할
TF-IDF로 드문 조각에 가중치

모델

단순 규칙 · 나이브 베이즈
· 로지스틱 회귀 · 선형 SVM

평가 지표

정확도

기본 성능

Macro-F1


상품수가 적은 카테고리도 동등하게 반영

Top-3 정확도

모델 추천 후보 3개 중 정답이 있는 비율

기본 성능

정확도 (%)



모델	정확도	Macro-F1	Top-3
단순 규칙(카테고리명 포함)	22.8 ± 0.8%	0.301	–
나이브 베이즈	90.0 ± 0.4%	0.812	95.1%
로지스틱 회귀	92.9 ± 0.2%	0.872	96.3%
선형 SVM	93.0 ± 0.2%	0.866	96.2%

단순 규칙이 아무것도 예측하지 못한 비율

76.7%

상품명에 카테고리명 없음

기본 모델

로지스틱 회귀

SVM과 성능이 같고, 확신도를 함께 제공

상위 3개 후보 안에 정답이 있는 비율

96.3%

카테고리 후보를 제시하는 서비스라면 적용 가능한 수준

무작위 분할 5회 반복 평균 ± 표준편차 · 76.7%는 첫 번째 분할 결과 · 선형 SVM은 확신도를 내지 않아 Top-3를 점수 순위로 계산

설계 검증

검증 1. 상품명 표현 방식 비교

자르는 단위 · 점수 방식	정확도	Macro-F1
글자 조각 · TF-IDF (현재)	92.8%	0.871
글자 조각 · 단순 횟수	92.3%	0.858
단어 · TF-IDF	86.8%	0.804

자르는 단위 · 글자 vs 단어

+ 6.0%p

점수 방식 · TF-IDF vs 단순 횟수

+ 0.5%p

처음 보는 코드 예시 평가 단어의 21.2%가 학습에 없던 단어

단어

6PK2390 → 학습에 없던 단어라 단서 없음

글자 조각

6P · PK · K2 ... → "PK"를 V벨트 규격으로 학습

→ 성능의 근거는 TF-IDF가 아니라 글자 단위 분할

검증 2. 카테고리 기준값 비교

기준값	카테고리	커버리지	Macro-F1	최소 평가
5	136	98.8%	0.727	1건
10	101	96.7%	0.821	2건
20	74	93.4%	0.878	4건
30	57	89.8%	0.903	6건
50	42	84.6%	0.932	10건

10 이하 · 평가 성립 X

최소 평가 1~2건 → F1이 0 또는 1


20 초과 · 이득 급감

커버리지 1%p당 Macro-F1 0.017 → 0.007

기준을 올리면 어려운 카테고리가 빠질 뿐 → 성능이 가장 높은 기준값을 고르지 않음

→ 20 = 평가 최소 4건 확보 + 커버리지 93.4% 유지

공급사 단위 분할 성능



로지스틱 회귀 정확도 (무작위 → 공급사)

92.9% → 76.8%

약 16%p 하락 · 공급사별 표기 형식에 일부 의존

회차	무작위	공급사	제외 건수
1	92.9%	81.1%	0
2	92.8%	84.5%	0
3	93.2%	61.2%	72
4	92.6%	83.4%	0
5	92.9%	73.9%	0

3회차: 한 공급사의 상품이 통째로 평가 쪽에 들어감
→ 그 공급사에만 있던 카테고리는 학습에 없어서, 해당 상품 72건은 채점에서 제외
공급사 단위 분할에서는 선형 SVM(81.2%)이 더 높음 → 모델 간 우열은 단정하기 어려움

공급사 단위 분할의 편차 (로지스틱 회귀)

± 9.7%p

특정 공급사 데이터 쏠림의 영향으로 5회 반복 실험의 평균과 편차로 결과 제시

오류 분석

1회차 평가 데이터 2,166건 중 오답 153건 (7.1%)

F1 점수 하위 카테고리

1

검토 필요

카테고리 경계 모호

냉각팬모터 → 라디에이터 7건
컨덴서웬 → 컨덴서 5건
라디에이터 → 컨덴서 4건

냉각 계통 부품명 유사
→ 카테고리 통합 검토 필요

2

판별 불가

차종만 기재

"라세티", "A3"
"메가트럭"
"K5,YF,LF"

부품 정보 없음

3

판별 불가

범용 명칭

"하우징", "슬리브"
"SEAL SET"
"CAP SUB-ASSY"

부품 유형 특정 불가




→ 2·3은 상품명 안에 부품 정보가 아예 없어서 어떤 부품인지 판별 불가 = 데이터 한계로 인한 성능 상한

하위 카테고리 대부분 평가 10건 이하 → Macro-F1이 정확도보다 낮은 원인 · 냉각팬모터(평가 27건)는 건수가 아닌 경계 모호가 원인

미분류 상품 적용

확신도 기준별 자동 분류 비율 (804건)



규칙으로는 불가능했던 분류 · 현장 용어 · 영문 · 규격 코드

상품명	예측 카테고리	확신도
발전기	알터네이터	0.825
스타터	스타터모터	0.840
6PK2390	V벨트	0.938
외벨트 6DPK1697	V벨트	0.937
PULLEY IDLER	아이들베어링	0.931
THERMOSTAT ASSY	써모스탯	0.927

운영 방식 · 확신도 0.8 기준

자동 분류

636건 (79.1%)

담당자 검토

168건

한계와 다음 단계

확인된 한계

공급사가 바뀌면 92.9% → 76.8%

표기 형식에 일부 의존 · 편차 $\pm 9.7\%p$

소수 카테고리 F1 0.40~0.64

냉각 계통은 경계 모호가 원인

208개 중 74개 카테고리만 학습

상품명 기준 커버리지 93.4%

총돌 · 범용 명칭 142개 제외

상품명만으로 판별할 수 없는 데이터

2차 목표

- 1 사전학습 언어모델 등 딥러닝 모델 적용
- 2 공급사 분할 성능으로 표기 형식 의존도 감소 검증
- 3 소수 카테고리 대응 · 학습 카테고리 확대
- 4 냉각 계통 카테고리 경계 재정의 검토
- 5 확신도 기반 자동 분류 기준 확정

평가 기준

분할 파일 고정 → 2차도 같은 데이터로 비교 · 공급사 분할은 5회 각각 로지스틱 회귀와 비교